ESCUELA POLITÉCNICA NACIONAL

cec·epn
CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

Día 4: Random Forest para series de tiempo



Expositor: Jonathan Rosero

Agenda del día

10 min	**De la serie a la tabla**	Cómo una columna se vuelve un problema de Machine Learning
15 min	**Árboles y bosques**	Repaso del Módulo 3 con dibujos
15 min	**Sobreajuste y validación temporal**	TimeSeriesSplit: el origen móvil en bloques
15 min	**Hiperparámetros e importancia**	Las perillas del bosque y qué miró
15 min	**Test y pronóstico a varios meses**	Recursivo frente a directo
70 min	**Notebook del Día 4**	Todo el recorrido en Python

Al terminar el día podrás

- Convertir una serie en una tabla de aprendizaje supervisado sin fuga de información
- Explicar con un dibujo qué hace un árbol de decisión y por qué un bosque promedia muchos
- Validar con TimeSeriesSplit y explicar por qué un K-Fold mezclado engaña
- Ajustar los hiperparámetros principales y leer la importancia de variables
- Comparar el Random Forest con el PM12 y con los modelos del Día 3
- Explicar la diferencia entre pronóstico recursivo y directo

Lo que traemos del Día 3

La escalera

ARIMA → SARIMA → SARIMAX: cada peldaño mejoró en validación.

El Test

PM12 0.286 · ARIMA 0.308 · SARIMAX 0.319 · SARIMA 0.323.

El puente

Un AR(1) es una regresión sobre una tabla de rezagos. Hoy: Random Forest sobre esa tabla.

? Pregunta del día: ¿puede el Machine Learning vencer al PM12?

ESCUELA POLITÉCNICA NACIONAL

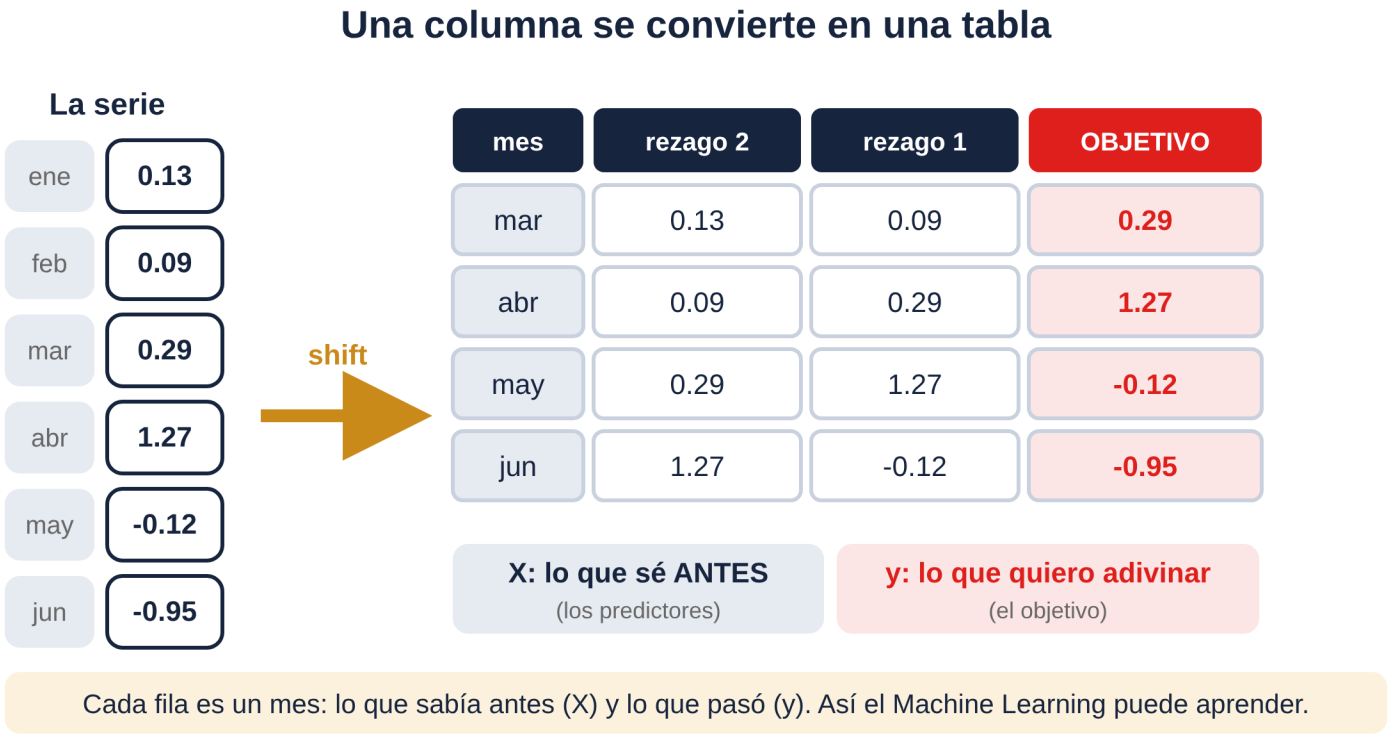
cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

01 De la serie a la tabla

Cómo una sola columna se vuelve un problema de Machine Learning

Una columna se convierte en una tabla



X = lo que sé antes del mes (predictores). y = lo que pasó ese mes (objetivo).

No es nuevo: el AR(1) ya era una tabla

Día 3

Tabla con rezago_1
+ regresión lineal
= AR(1)

Día 4

Tabla con 8 columnas
+ Random Forest
= relaciones no lineales

	AR / ARIMA	Random Forest
Relación pasado-presente	una línea recta	cualquier forma (sí/no encadenados)
Columnas	rezagos de la serie (y exog)	rezagos, promedios, mes, otras series
Intervalos	sí, con fundamento estadístico	no directamente

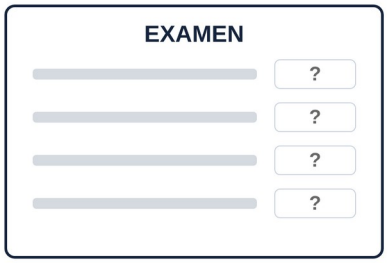
Qué columnas crear: cada una con su evidencia

Columna	Qué es	¿Por qué? (evidencia)
rezago_1	la inflación del mes anterior	el rezago más fuerte en la ACF y la PACF
rezago_2, rezago_3	hace 2 y 3 meses	la ACF sigue fuera de la franja
rezago_6	hace 6 meses	bastón en la PACF (Día 2)
rezago_12	el mismo mes del año pasado	estacionalidad
media_3	promedio de los 3 meses anteriores	el nivel reciente
media_12	promedio de los 12 meses anteriores	**¡la línea base PM12!**
mes	1 a 12	el calendario (inicio de clases, fiestas)

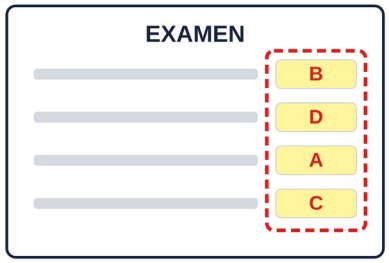
Primero entender la serie (Días 1 a 3), después elegir las columnas. El orden importa.

La regla de oro: solo el pasado

Fuga de información: estudiar con las respuestas pegadas



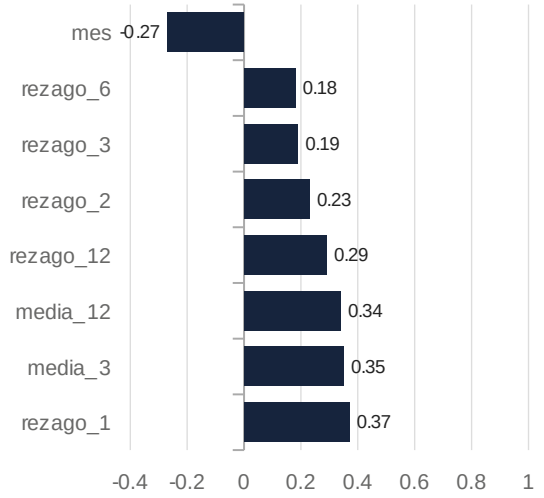
Bien: solo con lo que ya sabía



Trampa: la respuesta ya está en la hoja

nota perfecta en práctica, desastre en el examen real

Correlación con el objetivo



Prueba rápida: si una columna tiene correlación ≈ 1 con el objetivo, sospecha de un shift olvidado.

En código: `primero y.shift(1), después .rolling(12).mean()`

Train y Test por fecha, nunca al azar

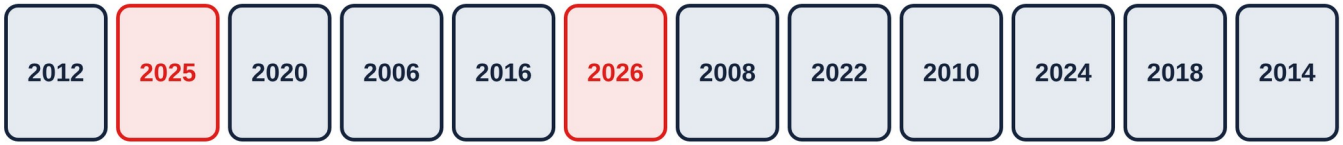
¿Cómo separo los meses para entrenar y para probar?

BIEN: cortar el mazo por fecha



Entreno con el pasado (azul) y pruebo con el futuro (rojo): como en la vida real

MAL: barajar los meses al azar



El modelo entrena con 2026 para "pronosticar" 2008: usa el futuro

Train: 228 meses (2006–2024). Test: 20 meses (2025 – ago 2026). El Test no se toca hasta el final.

ESCUELA POLITÉCNICA NACIONAL

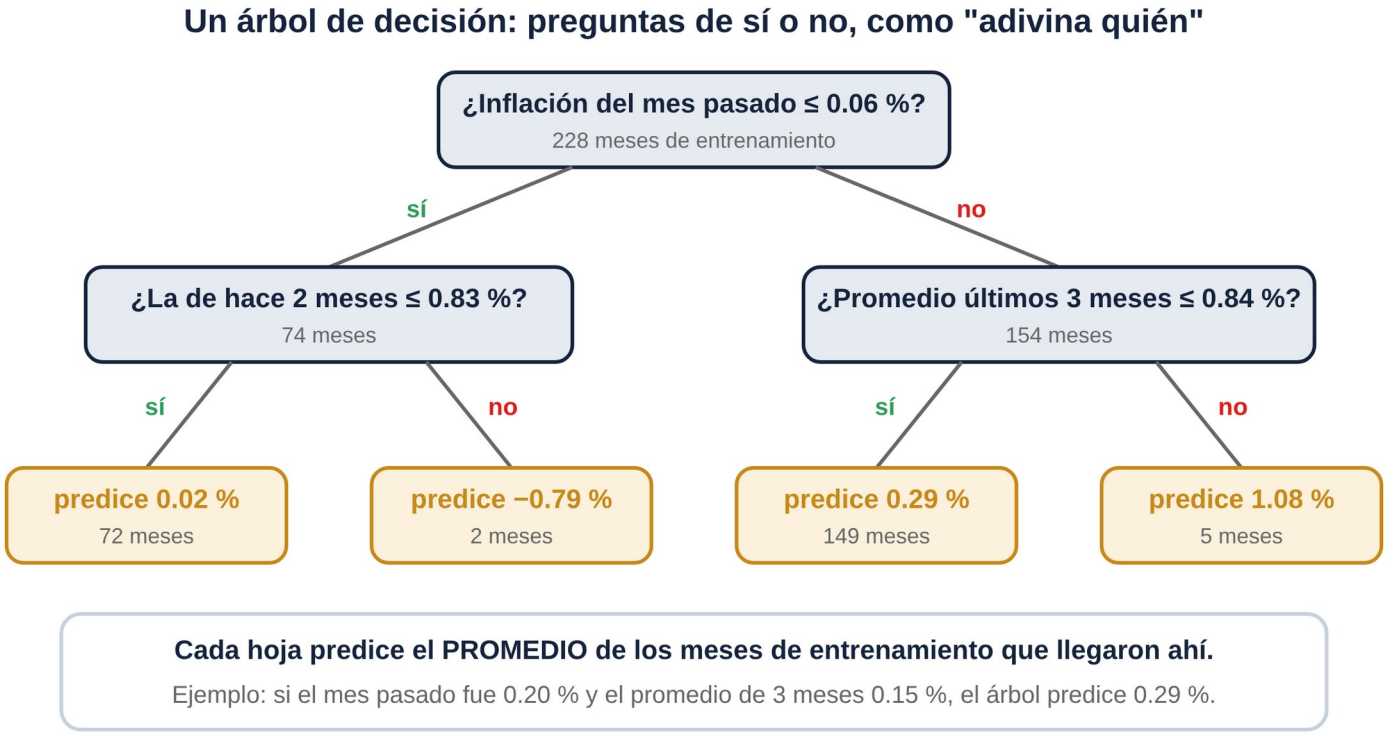
cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

02 Árboles y bosques

Repaso del Módulo 3, con dibujos

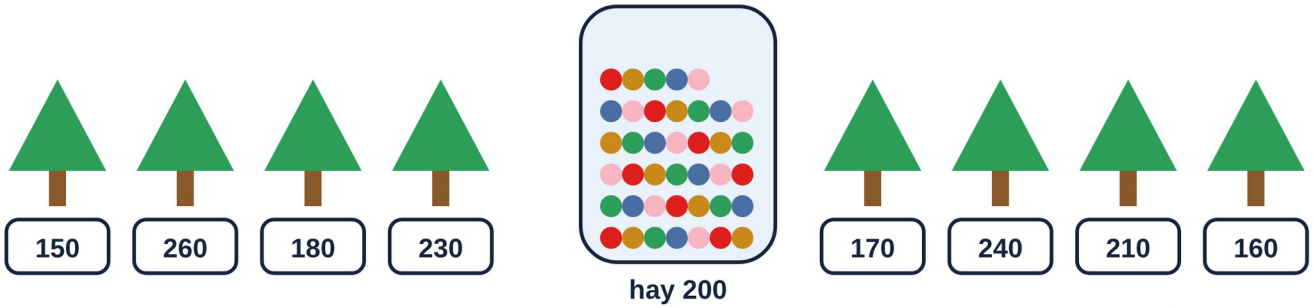
Un árbol de decisión: preguntas de sí o no



Las preguntas no las ponemos nosotros: el árbol elige las que más reducen el error.

Un bosque: la sabiduría de la multitud

¿Cuántos caramelos hay en el frasco?



cada árbol se equivoca... ...para un lado o para el otro

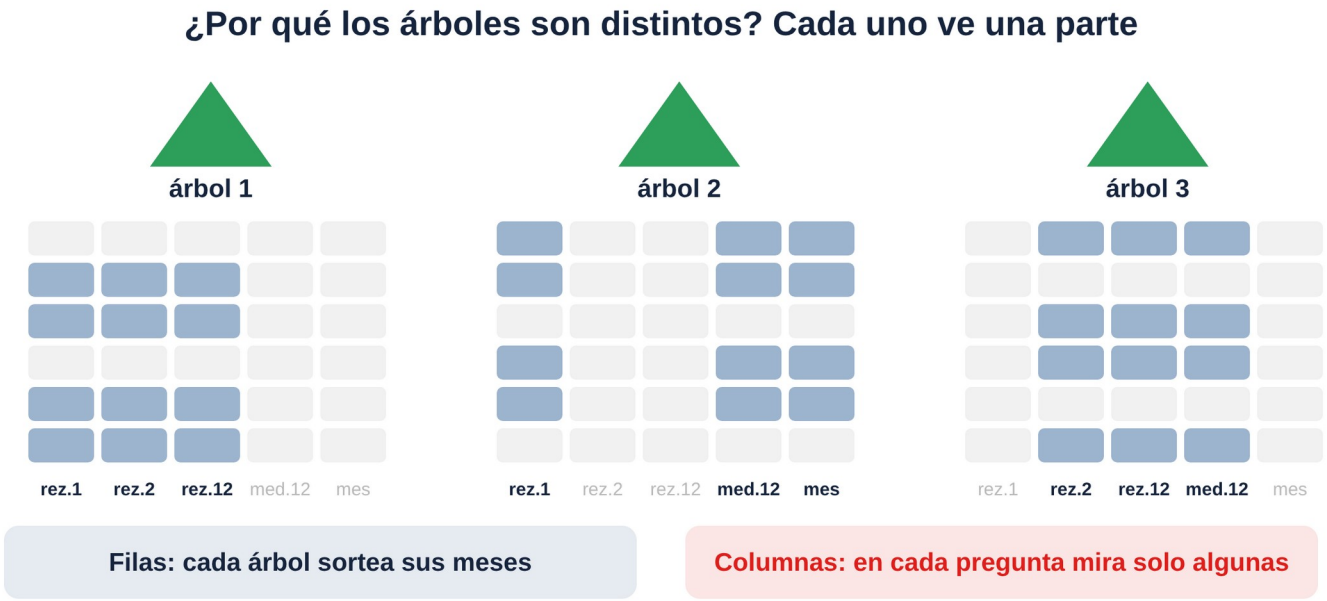
Promedio de los 8 árboles: 200

(150+260+180+230+170+240+210+160) / 8

Random Forest = muchos árboles distintos que votan; sus errores se cancelan al promediar.

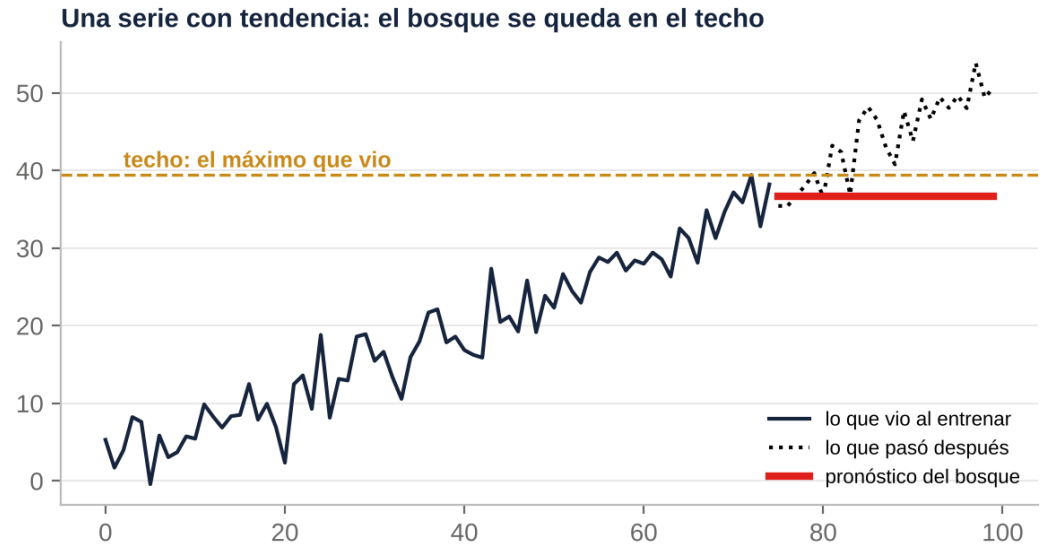
Random Forest = muchos árboles distintos que votan. El promedio se equivoca menos que cada uno.

¿Por qué los árboles son distintos?



Filas al azar + columnas al azar = árboles distintos. Por eso el promedio funciona.

Lo que un bosque no puede hacer: salir de lo que vio



- **Cada hoja = un promedio** de meses que ya vio.
- **Nunca supera el máximo** de su entrenamiento.
- **Solución:** trabajar con la serie que oscila (la inflación) o con la diferenciada.

Random Forest: velocímetro sí, odómetro no. La misma lección de la diferenciación del Día 3.

Serie simulada.

ESCUELA POLITÉCNICA NACIONAL

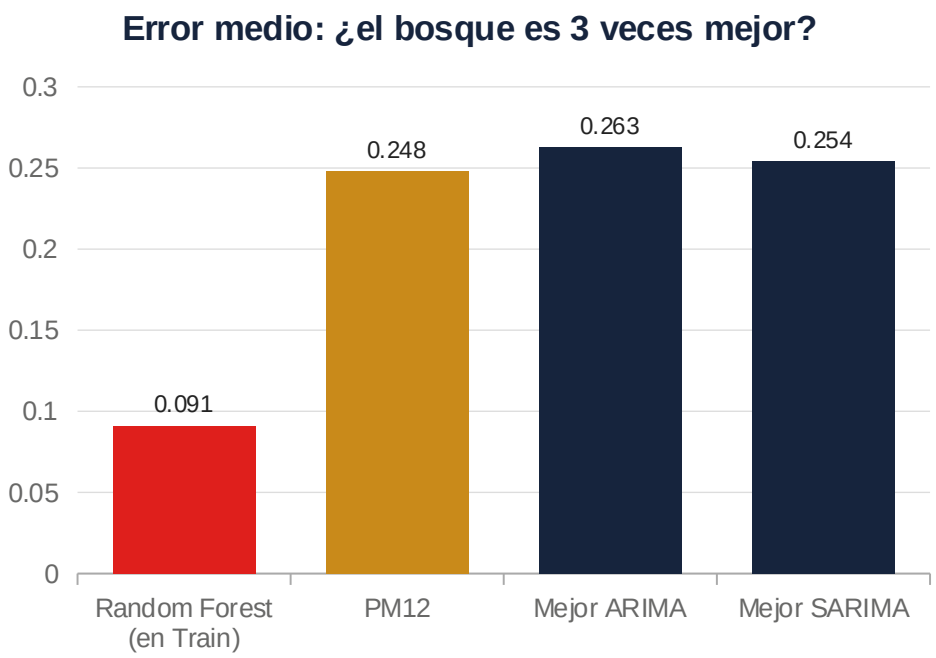
cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

03 Sobreajuste y validación temporal

Por qué un error de 0.09 no es una buena noticia

Primer bosque: ¿un modelo casi perfecto?

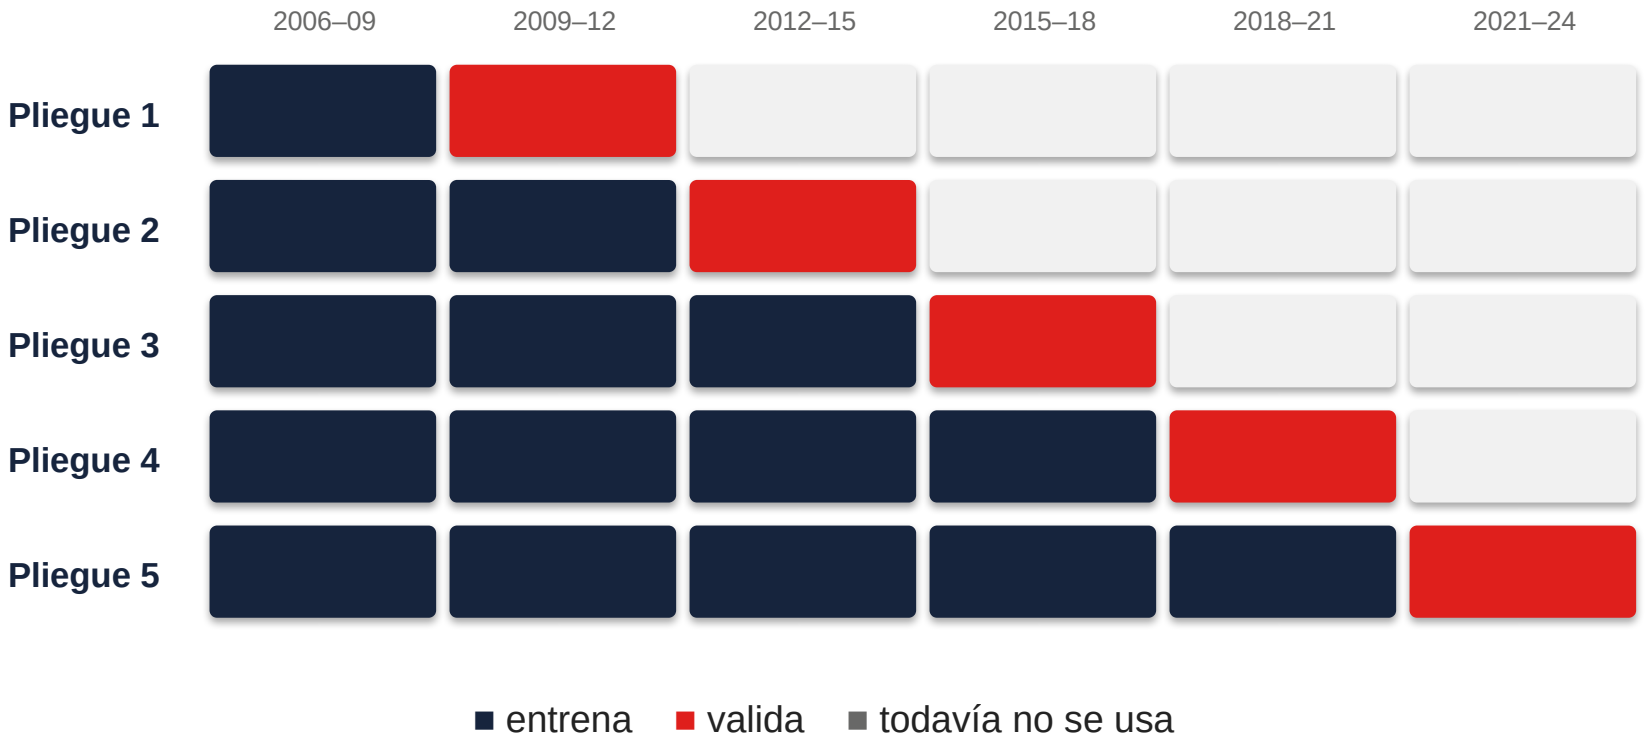


- **0.09 en Train** mide cuánto memorizó, no cuánto sabe.
- **Hojas de un solo mes:** cada árbol se aprende la guía de memoria.
- **La pregunta real:** ¿cómo le va con meses que no vio?

Como el estudiante que memoriza la guía: saca 10 en la práctica y no puede resolver un ejercicio nuevo.

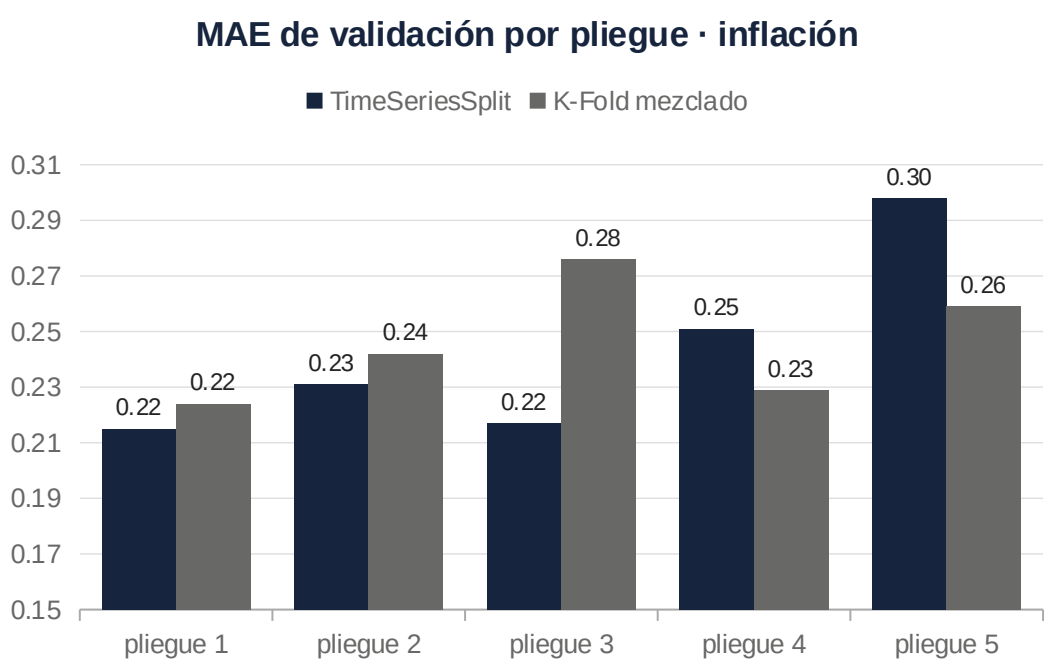
PM12, ARIMA y SARIMA: MAE de validación del Día 3 (2015–2024).

TimeSeriesSplit: el origen móvil en bloques



Siempre entrena con el pasado y valida con el bloque siguiente. 190 meses validados, sin tocar el Test.

¿Y si mezclamos al azar? En la inflación casi da igual...

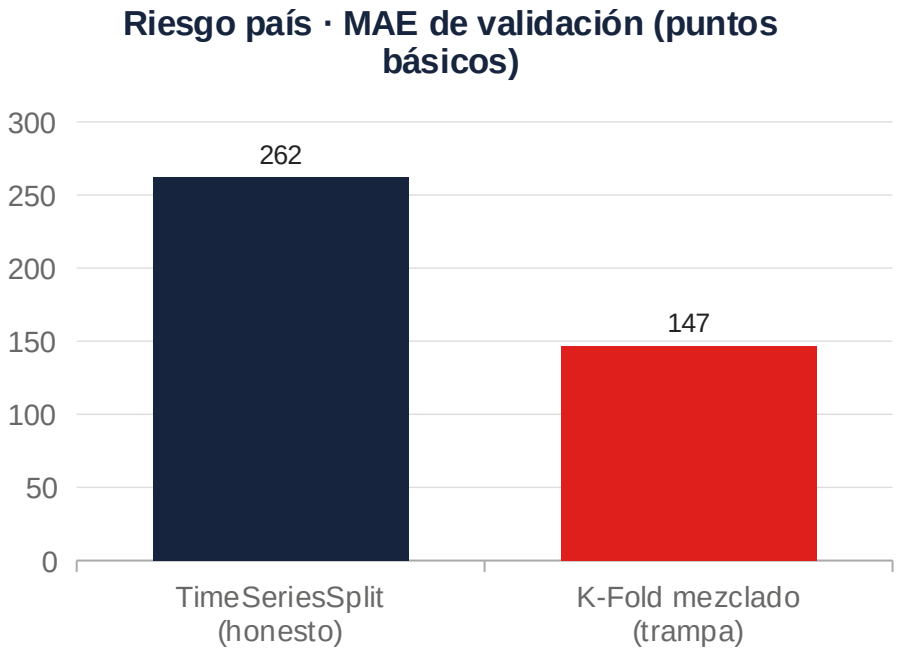


Esquema	MAE medio
TimeSeriesSplit	0.242
K-Fold mezclado	0.246

El último pliegue (2021–2024, con los choques de 2024) es el más difícil.

? ¿Entonces da igual mezclar? Veamos una serie con más memoria.

...pero en el riesgo país, mezclar es copiar al vecino

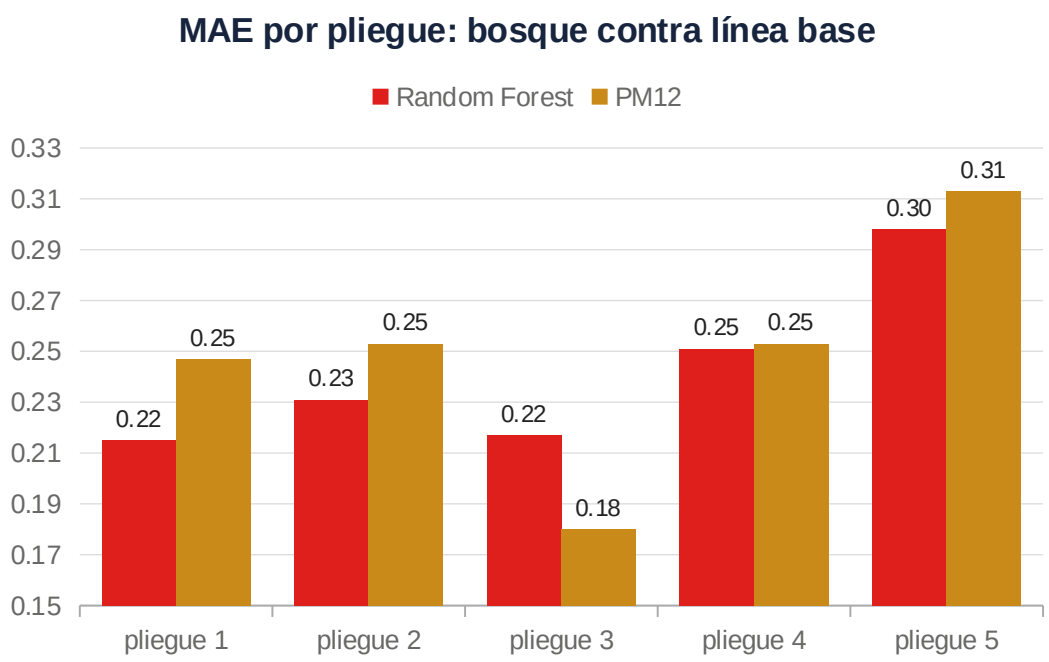




Al mezclar, el modelo entrena con los meses vecinos del que valida.

Como copiar al compañero de al lado: la nota sube un 44 %, pero no es tuya. Con series que cambian poco, el K-Fold mezclado engaña mucho.

Comparar con la línea base en los mismos pliegues



Modelo	MAE medio
Random Forest (por defecto)	0.242
PM12	0.249

En validación el bosque ya le gana al PM12 por muy poco. ¿Ajustando las perillas, más?

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

cec·epn U.C.C. Unidad de Capacitación y Certificación

04

Hiperparámetros e importancia

Las perillas del bosque y qué miró para decidir

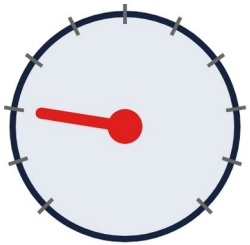
Las perillas del bosque

Hiperparámetros: las perillas que ajustamos antes de entrenar



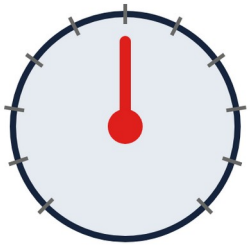
max_depth

¿cuántas preguntas seguidas puede hacer?



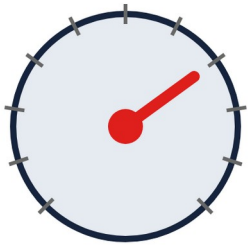
min_samples_leaf

¿cuántos meses mínimo en cada hoja?



max_features

¿cuántas columnas mira en cada pregunta?



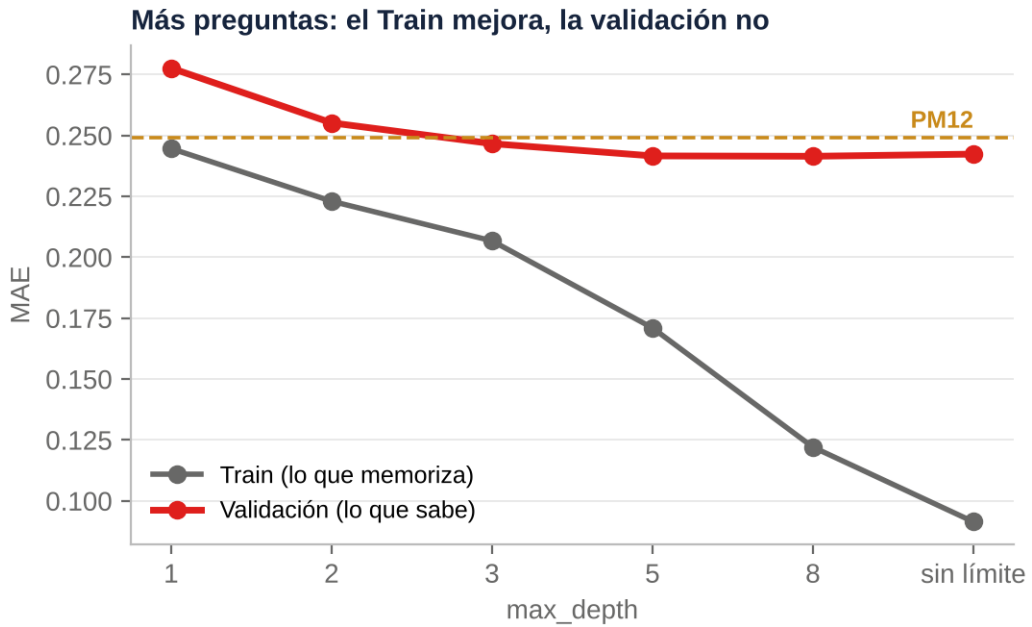
n_estimators

¿cuántos árboles votan?

Muy bajo: el modelo no aprende (subajuste). Muy alto: memoriza (sobreajuste).

Muy poco: no aprende (subajuste). Demasiado: memoriza (sobreajuste). Buscamos el punto medio.

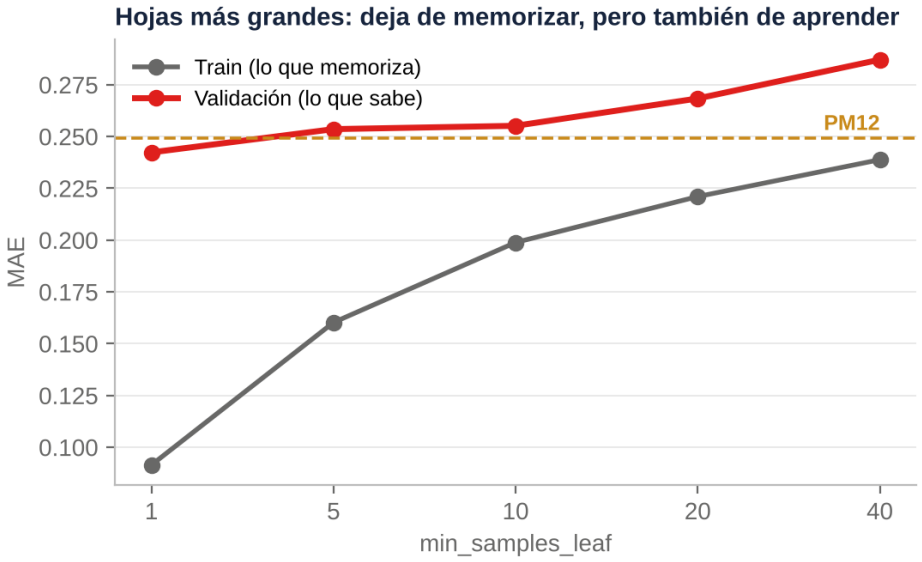
max_depth: la curva clásica del sobreajuste

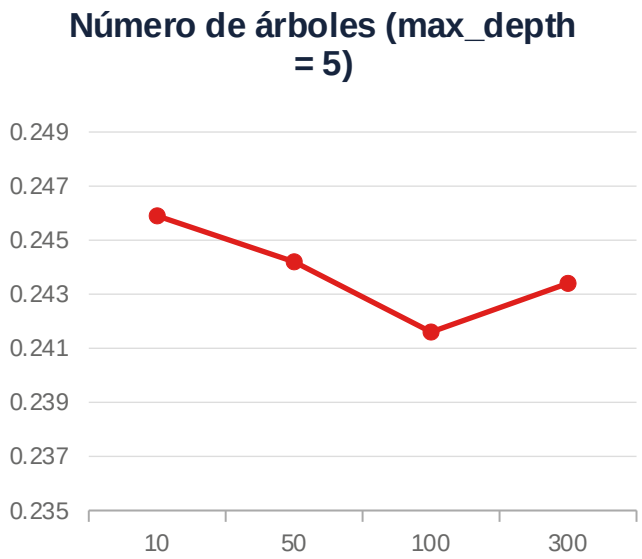


- **Train:** baja sin parar.
- **Validación:** mejora hasta 3–5 y se estanca.
- **La brecha** entre las dos curvas es el sobreajuste.

Más profundidad no es más conocimiento: después de 5 preguntas, el árbol solo memoriza.

min_samples_leaf y n_estimators





Hojas muy grandes = casi una media histórica. Más árboles = más estable, nunca más sobreajuste.

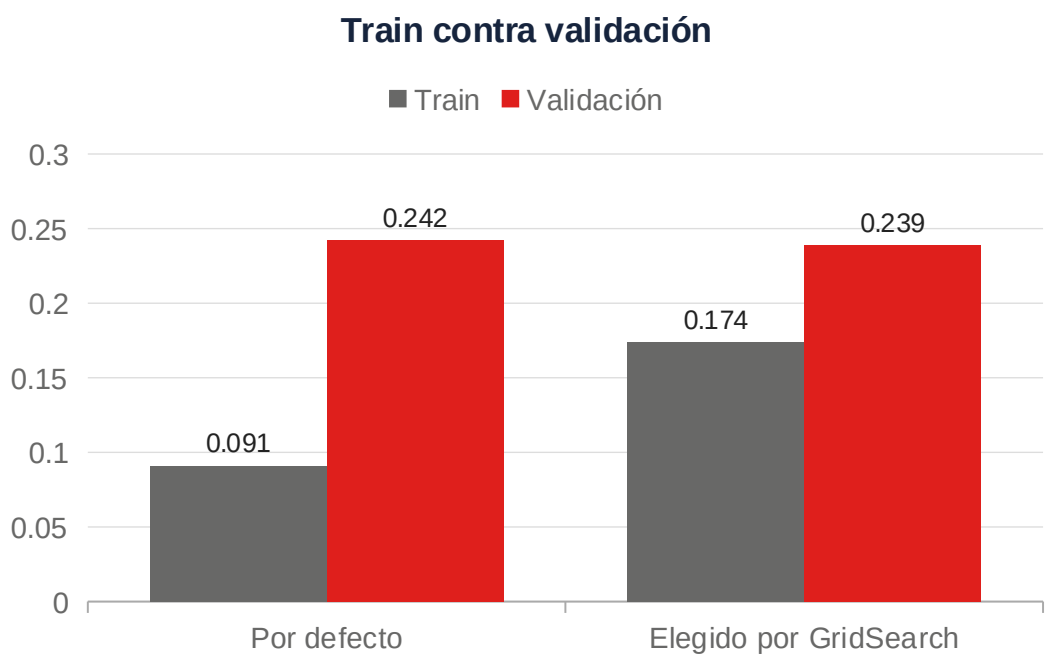
GridSearchCV: probar todas las combinaciones

max_depth	min_samples_leaf	max_features	MAE validación	variación entre pliegues
5	1	0.5	0.239	0.035
None	1	0.5	0.240	0.033
3	1	0.5	0.241	0.030
5	1	1.0	0.242	0.030
None	1	1.0	0.242	0.031

- **Ganadora:** profundidad 5, hojas de 1 mes, mitad de las columnas: 0.239.
- **Las 5 mejores** están a menos de 0.01; la variación entre pliegues es ≈ 0.03. La elección no es crítica.
- **Frente al PM12** en los mismos pliegues (0.249): mejora ≈ 0.01. Pequeña.

`cv = tscv` — la única diferencia con el Módulo 3: los pliegues respetan el tiempo.

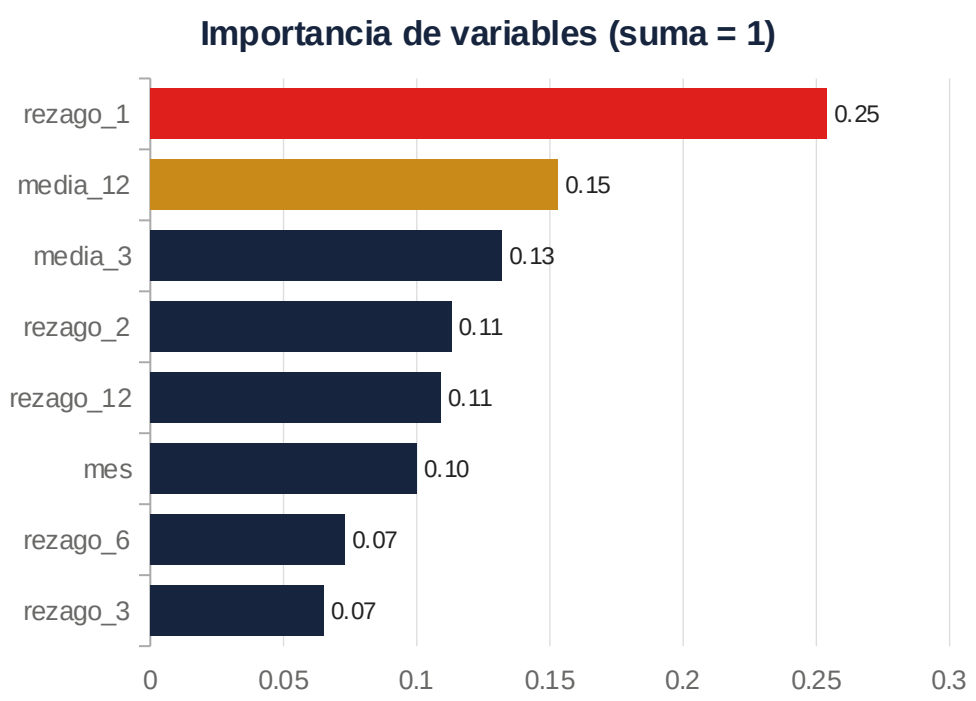
El modelo elegido: menos memoria, misma validación



- **Por defecto:** 0.09 contra 0.24: memoriza.
- **Elegido:** 0.17 contra 0.24: la brecha se achica.

Ajustar las perillas no bajó mucho la validación, pero sí la memorización. Eso es un modelo más sano.

¿Qué miró el bosque para decidir?



Columna	Lo que ya sabíamos
rezago_1	el más fuerte en ACF y PACF
media_12	la línea base: el nivel de fondo
rezago_12, mes	la estacionalidad débil
rezago_3, rezago_6	aportan poco

El bosque redescubrió la ACF: el mes anterior, el nivel de fondo y el patrón anual. Predictivo, no causal.

ESCUELA POLITÉCNICA NACIONAL

cec·epn CENTRO DE EDUCACIÓN CONTINUA

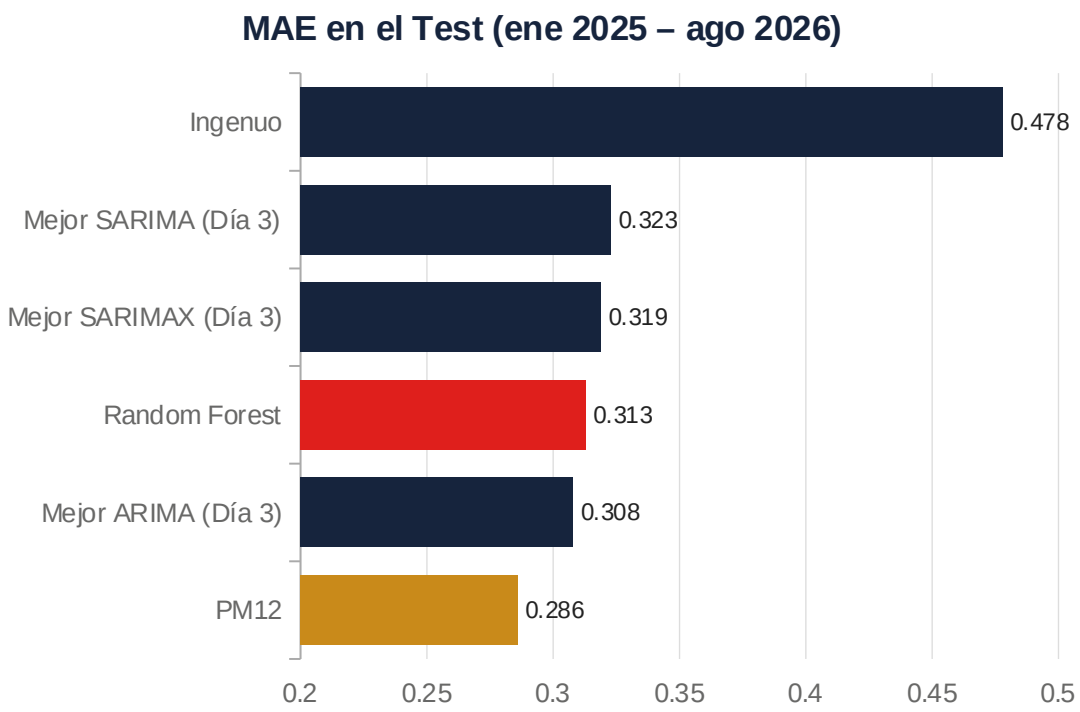
cec·epn U.C.C. Unidad de Capacitación y Certificación

05

Test y pronóstico a varios meses

La prueba de fuego y dos formas de mirar lejos

Test, una sola vez: ¿le ganó al PM12?

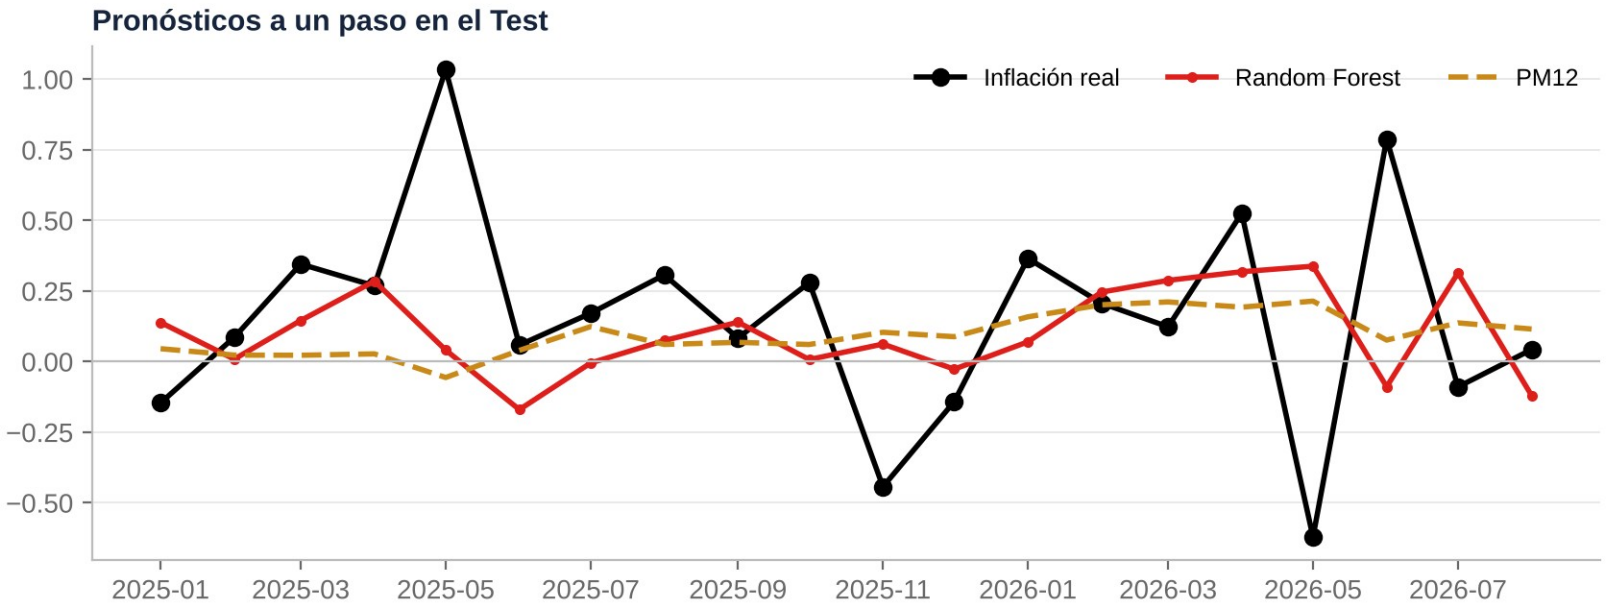


- **PM12 sigue primero.**
- **El bosque** empata con el mejor ARIMA y supera al SARIMA y al SARIMAX.
- **Validación ≠ Test:** ganó por poco en validación, no en el Test.

Con una serie tan ruidosa, la complejidad casi no tiene información extra que aprovechar.

SARIMAX: MAE del Test del Día 3. Los demás, calculados igual que en el notebook.

El bosque reacciona; el PM12 se queda quieto



Como el portero en un penal: el bosque se lanza hacia un lado; el PM12 se queda en el centro. Si los tiros son al azar, quedarse en el centro falla menos.

Fuente: INEC (IPC) y BCE; cálculos propios.

El problema: para octubre me falta septiembre

Septiembre
rezago 1 = agosto: ✓ lo tengo

Octubre
rezago 1 = septiembre: × no existe

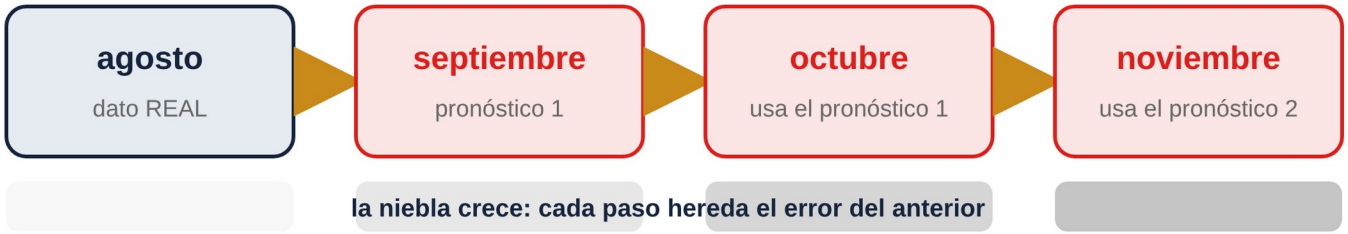
Noviembre
rezago 1 = octubre: × no existe

? ¿Qué hacemos con los rezagos que todavía no existen?

Dos soluciones: usar mis propios pronósticos (recursiva) o entrenar un modelo para cada horizonte (directa).

Estrategia recursiva: pisar mis propias huellas

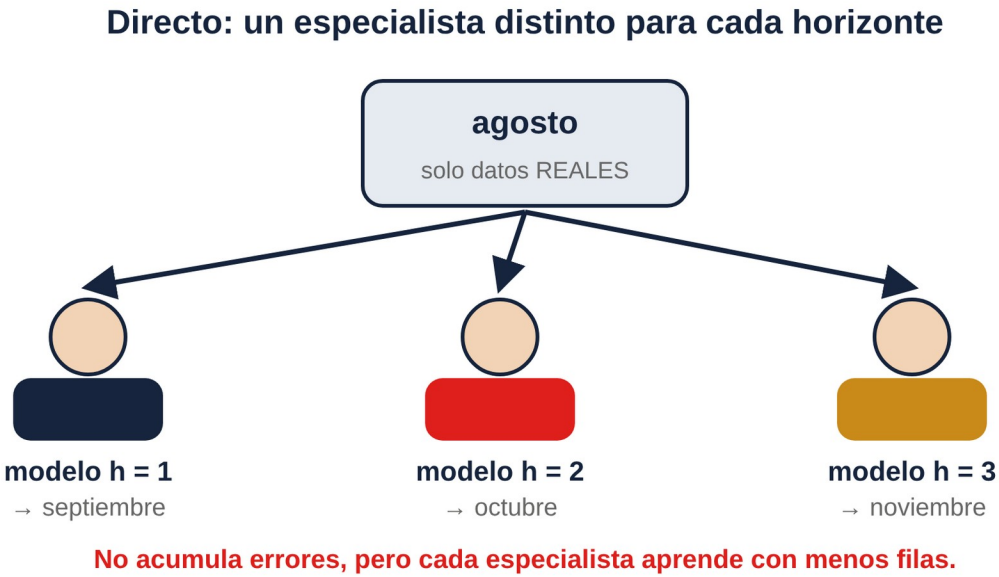
Recursivo: cada paso se apoya en el pronóstico anterior



Como caminar en la niebla pisando tus propias huellas:
si la primera huella se desvió, las siguientes también. Ventaja: un solo modelo.

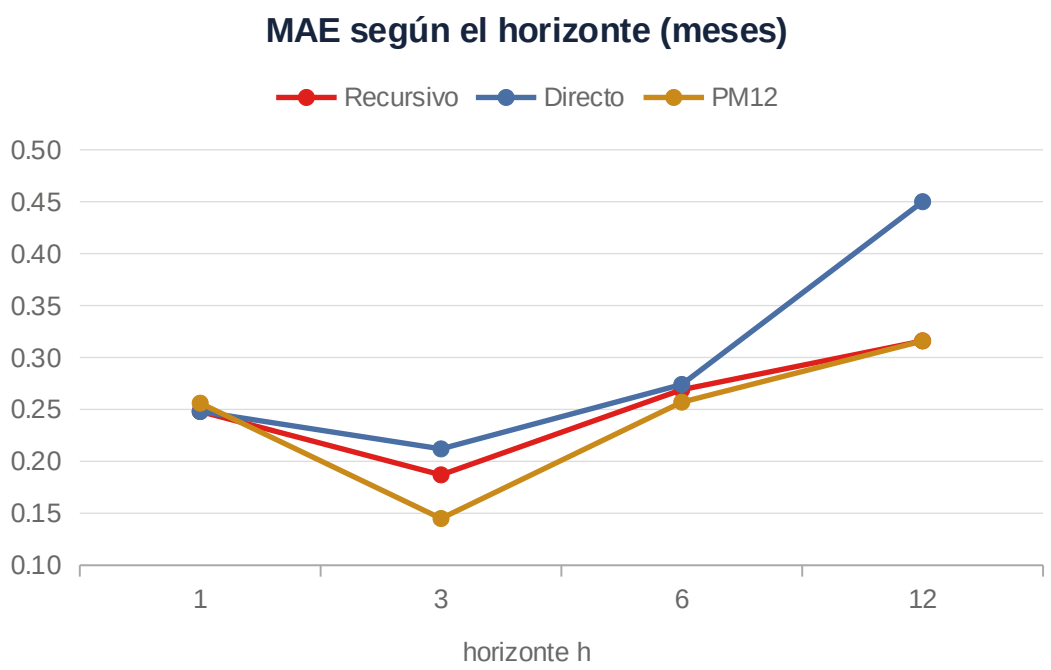
Recursivo: un solo modelo; cada paso hereda el error del anterior.

Estrategia directa: un especialista por horizonte



Directo: no acumula errores, pero hay que entrenar un modelo por horizonte, con menos filas.

¿Cuál funciona mejor? 18 orígenes, cuatro horizontes

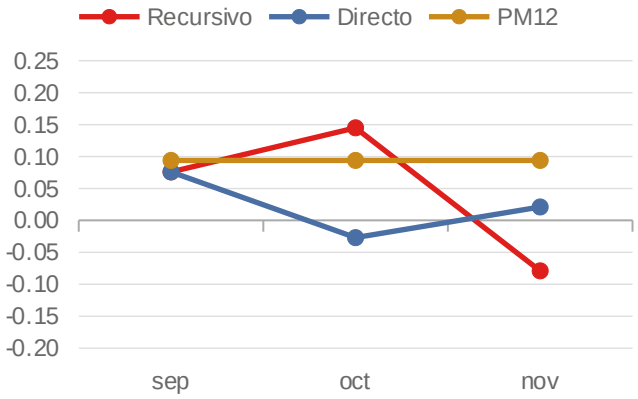


Situación	Estrategia
horizontes cortos, dinámica fuerte	recursiva
horizontes largos, muchos datos	directa
series muy ruidosas (la inflación)	comparar con la línea base: a menudo ninguna gana

Mirar lejos no ayuda al bosque: desde 3 meses, el PM12 iguala o gana a las dos estrategias.

Pronóstico de septiembre a noviembre de 2026

Mes	Recursivo	Directo	PM12
sep 2026	0.076	0.076	0.094
oct 2026	0.145	-0.027	0.094
nov 2026	-0.079	0.021	0.094



- **Septiembre:** las dos estrategias coinciden (mismo modelo).
- **Diferencias de décimas:** mucho menores que el intervalo del Día 3 (más de 1 punto).
- **Sin intervalos:** el bosque no los da; los construiremos el Día 6.

Reto de cierre: exportaciones

- Trabaja con la variación mensual de exportaciones (el velocímetro, no el odómetro).
- Construye la misma tabla de 8 columnas y revisa que no haya fuga.
- Valida con TimeSeriesSplit y compara con el PM12 en los mismos pliegues.
- Ajusta max_depth y mira la importancia de variables: ¿qué columna usa más?
- ¿Le gana el bosque al PM12 en esta serie? ¿Por qué crees que sí o que no?

Pista: una serie con más estructura le da al bosque más información que aprovechar.

Lo que nos llevamos hoy

De la serie a la tabla

shift antes de rolling; cada columna con su evidencia; sin fuga.

Árboles y bosques

Preguntas de sí o no; muchos árboles distintos que votan.

Validación temporal

TimeSeriesSplit siempre. Mezclar es copiar al vecino.

El resultado

El bosque empata con el mejor ARIMA. El PM12 sigue ganando.

Mañana: darle al bosque información que el PM12 no tiene (petróleo, liquidez) y combinarlo con ARIMA. Actividad 3.

Para repasar en casa

Tema	Dónde repasarlo
Árboles, Random Forest, hiperparámetros	Módulo 3, Días 2, 3 y 6
Origen móvil y horizontes	Día 2 de este módulo
La tabla de rezagos	Día 3, parte 7 del notebook
Todo el recorrido de hoy	04_Dia4_Random_Forest_para_Series.ipynb (local o Colab)

Checklist del notebook: shift antes de rolling, TimeSeriesSplit, línea base en los mismos pliegues.